TECHNICAL WHITEPAPER & MASTER ARCHITECTURE MANUAL

Platform AI CV Screening & Ranking

Arsitektur Lengkap Rekayasa Sistem Seleksi CV Berbasis Hybrid AI & Rule-Based Deterministik: Dari Pembersihan Berkas, Anonimisasi PII, Vektorisasi Semantik pgvector, hingga Penilaian Kepatuhan Ketenagakerjaan.

PENGEMBANG / PEMILIK	ENGINE AI SEMANTIK	STANDAR REGULASI	STATUS SISTEM
Muhammad Rifqi Setiawan	Harrier-270m (640d pgvector)	UU PDP & SE Menaker 2025	Production v2.0 (Port 8110)

0 Ringkasan Eksekutif & Peta Alur Arsitektur End-to-End

Proses seleksi resume (CV) manual menghadapi beban volume masif, format tata letak yang tidak seragam, dan bias subjektif manusia. Platform ini dibangun dengan arsitektur **Hybrid AI & Deterministik** yang mengawinkan kecepatan pemrosesan data, akurasi semantik representasional, dan kepatuhan hukum tanpa halusinasi.

🗺️ Alur Master 6 Tahapan Pipeline (The 6-Stage Master Architecture)

Tahap 1: Job Description & Requirement Compilation — `Kriteria & Bobot`

Penyusunan naskah lowongan kerja (manual / template industri), parsing kriteria berbasis LLM & aturan konsep, pembobotan 4 kategori terkalibrasi, dan persetujuan terkunci (Human-in-the-Loop).

▼

Tahap 2: Ingestion & Pre-Flight Gatekeeper — `Fail-Fast`

Penerimaan dokumen (PDF/DOCX/ZIP), validasi header biner Magic Bytes, deduplikasi hash SHA-256, dan pencegatan berkas bukan-CV (Ijazah/KTP/Surat Lamaran/Portofolio) via Triple-Filter.

▼

Tahap 3: Extraction & Smart Boundary Isolation — `Parser & Anchor`

Pemisahan lampiran portofolio multi-halaman tanpa memotong CV, hybrid parser (PyMuPDF + Docling visual AI), normalisasi rentang tanggal, dan triangulasi 5 sinyal nama kandidat anti-headline bias.

▼

Tahap 4: PII Redaction & Privacy Separation — `UU PDP`

Pemisahan identitas sensitif ke tabel terisolasi (candidate_identities), pembersihan total data demografi (gender, agama, usia), penyamaran token [NAMA]/[EMAIL], dan pembuatan kode acak (C-0042).

▼

Tahap 5: Vector Embedding & Hybrid Semantic Retrieval — `pgvector + FTS`

Vektorisasi 640-dimensi Harrier-270m, pencarian semantik HNSW Cosine Similarity digabung dengan PostgreSQL Full-Text Search menggunakan Reciprocal Rank Fusion (RRF k=60) untuk mengambil bukti riil CV.

▼

Tahap 6: Multi-Criteria Scoring, Banding & HR Governance — `Ranking`

Skoring dua lapis (Kriteria x Kategori), evaluasi kriteria Wajib (MUST_HAVE capping), penentuan Band A/B/C/R, gate kelayakan administratif terpisah, dan leaderboard interaktif di Web UI.

1 Tahap 1: Job Description & Requirement Compilation

Tahap pertama adalah fondasi dari seluruh proses penilaian. Sistem tidak membebankan penulisan rumus rumit kepada HR, melainkan menyediakan mesin kompilasi otomatis berbasis naskah Job Description (JD) alami di `src/domain/jd_compiler.py`.

📝 1. Input JD & Template Peran Industri

Recruiter dapat menempelkan teks lowongan bebas atau memilih **7 Role Template Siap Pakai** (Backend, Frontend, Data, Civil, QA, HR, dan Product) yang langsung memuat deskripsi standar ATS dan kriteria baku industri.

🛡️ 2. Policy Linter & Kualifikasi Sah (BFOQ)

Sistem menyaring syarat fisik irasional (seperti "good looking", "tinggi/berat badan"). Namun, kriteria **Agama** dan **Jenis Kelamin DIPERBOLEHKAN SECARA SAH** (*Bona Fide Occupational Qualification*) guna mendukung kebutuhan nyata instansi di Indonesia (seperti yayasan keagamaan, sekolah bernuansa khusus, asrama, dan peran spesifik).

⚖️ 4 Kategori Distribusi Bobot Standar Industri (Total 100%):

Secara default, sistem membagi porsi penilaian ke dalam 4 dimensi berimbang yang kini dapat diedit secara interaktif di dashboard Web UI:

- **Pengalaman Kerja (EXPERIENCE) — 40%:**
  Relevansi jabatan dan durasi riil pekerjaan.
- **Keterampilan Teknis (HARD_SKILLS) — 30%:**
  Bahasa pemrograman, tools, framework, dan metodologi.
- **Pendidikan & Sertifikasi (EDUCATION_CERT) — 15%:**
  Jenjang gelar, akreditasi almamater, dan sertifikasi.
- **Pencapaian & Kepemimpinan (ACHIEVEMENT) — 15%:**
  Dampak terukur, efisiensi kerja, dan kepemimpinan.

TINGKAT KEPENTINGAN	KATA KUNCI DI JD	BOBOT	KONSEKUENSI PENILAIAN (TAHAP 6)
🔴 `MUST_HAVE (Wajib)`	wajib, harus, minimal, essential	**20% – 25%**	Jika tidak terpenuhi, nilai akhir **langsung dibatasi (capped)** maks ke Band B (74%) atau Band C (49%).
🟡 `STRONG_PREFERENCE`	diutamakan, preferred, berpengalaman	**10% – 15%**	Menambah skor secara proporsional tanpa mengunci batas atas band kandidat.
⚪ `NICE_TO_HAVE`	nilai tambah, plus, keuntungan	**5% – 10%**	Poin bonus kompetitif untuk membedakan sesama kandidat di peringkat atas.

2 Tahap 2: Ingestion & Pre-Flight Gatekeeper

Setelah kriteria terkunci, dokumen pelamar masuk ke sistem. Tahap ini bertindak sebagai **firewall proteksi** untuk memilah berkas sah vs berkas berbahaya / salah unggah sebelum komputasi AI berjalan (`src/worker/sanitizer.py` & `classifier.py`).

🔍 Triple-Filter Framework: Bagaimana Sistem Mendeteksi CV vs Bukan-CV?

Lapis 1: Sanity Check & Magic Bytes Verification `Sanity`

Membaca header byte fisik file (misal `%PDF-`), memblokir file corrupt, virus, atau ekstensi palsu. Jika teks < 50 huruf dan 0 gambar, berkas ditolak (`INSUFFICIENT_CONTENT`).

Lapis 2: Negative Filter (Pencegatan Berkas Salah Unggah) `Auto-Reject`

Mencegat berkas non-CV menggunakan penanda leksikal kuat:

- **CERTIFICATE_ONLY:** Berisi kata *"Sertifikat, Ijazah, Transkrip Nilai"* tanpa riwayat kerja & skills.
- **ADMIN_DOC:** Berkas KTP, Kartu Keluarga, SIM, SKCK, NIK tanpa profil karir.
- **COVER_LETTER_ONLY:** Hanya surat lamaran naratif (*"Kepada Yth..."*) tanpa ringkasan pengalaman.
- **PURE_PORTFOLIO:** Berkas tebal (>3 halaman) berisi gambar desain murni tanpa riwayat karir dan kontak.

Lapis 3: Positive Consensus Scoring (Validasi CV Sah) `Verified CV`

Dokumen disahkan sebagai CV jika memiliki: (1) Kontak aktif terdeteksi (Email/No. HP), dan (2) Minimal 1 pilar karir: Seksi **Pengalaman Kerja** ATAU seksi **Pendidikan**.

3 Tahap 3: Extraction & Smart Boundary Isolation

Menguraikan dokumen pelamar adalah bagian krusial karena variasi layout CV sangat liar. Tahap 3 menggunakan empat subsistem rekayasa terpadu di `src/worker/adapter.py`:

📑 1. Smart Boundary Isolator

Alih-alih memotong paksa halaman secara kaku, modul `boundary.py` menganalisis **densitas rasio teks vs gambar per halaman**. Halaman 1–2 yang padat teks ditandai sebagai `CV_CORE`, sementara halaman lampiran portofolio/sertifikat dipisahkan ke metadata `portfolio_attachments` tanpa membingungkan parser.

🧩 2. Hybrid Multi-Engine Parser

Sistem menggunakan **PyMuPDF** untuk ekstraksi berkecepatan tinggi (skala milidetik). Jika terdeteksi layout Canva 2-kolom kompleks, tabel tanpa garis, atau skor keyakinan < 60%, sistem mengaktifkan **Docling (IBM Research)** yang membaca struktur dokumen secara visual dengan model *DocLayNet* dan *TableFormer*.

📅 3. Multi-Section & Shared-Year Regex

Modul `norm_single_date` menstandarkan seluruh format tanggal Indonesia/Inggris ke ISO (`YYYY-MM`), termasuk pola tahun bersama (*shared-year*, misal: "Juli - November 2023"). Seksi *'other'* disisir untuk menangkap judul pekerjaan yang terpisah oleh OCR pada CV scan gambar.

🎯 4. Orthogonal Anchor Triangulation

Mengeliminasi *headline bias* (kesalahan ATS umum yang mengira judul jabatan "Backend Developer" adalah nama pelamar). Sistem merekonsiliasi **5 sinyal konsensus silang**: Header CV, Nama File ATS, Username Email, Vanity URL LinkedIn, dan Pola Kalimat Pengantar (*"Nama saya..."*).

```
# Contoh Output Hasil Ekstraksi Tahap 3 (Data Terstruktur JSON): { "identity": { "full_name": "Ahmad Habibul Ulum", /* 100% Akurat via Triangulasi 5 Sinyal */ "email": "ahmad.habibul@gmail.com", "phone": "+6281234567890" }, "experiences": [ { "title": "Full Stack Web Developer", "organization": "PT Integra Sistem Optima", "start_date": "2023-07", "end_date": "2023-11", "duration_months": 5 } ], "skills": ["Python", "FastAPI", "PostgreSQL", "Docker", "React"], "portfolio_attachments": [{ "page": 3, "type": "PORTFOLIO_PROJECT" }] }
```

4 Tahap 4: PII Redaction & Privacy Separation

Kepatuhan hukum terhadap **UU Perlindungan Data Pribadi (UU PDP)** dan **Surat Edaran Menaker 2025** ditegakkan di tahap ini. Sebelum dievaluasi oleh mesin AI, data pribadi dipisahkan dan disamarkan di `src/worker/redaction.py`.

🔒 Arsitektur Isolasi Ganda (Dual-Path Data Isolation)

JALUR 1: DATA IDENTITAS SENSITIF

- Nama Lengkap Asli Pelamar
- Alamat Email & Nomor WhatsApp
- Tautan Akun LinkedIn & URL Portofolio
- Berkas PDF Dokumen Asli

Status: Dikunci terisolasi di tabel `candidate_identities`. Diberi kode anonim unik (misal: `C-0042`). Mesin AI penilaian **DILARANG KERAS** membaca tabel ini.

JALUR 2: MATCHING PROFILE EVALUASI

- Riwayat Pekerjaan & Tanggung Jawab
- Almamater & Jurusan Akademik
- Keahlian Teknis (Hard Skills)
- Proyek Nyata & Kualifikasi Khusus (Agama/Gender jika disyaratkan)

Status: Kontak pribadi disensor dengan token `[EMAIL]`, `[TELEPON]`. Nama disamarkan `[NAMA]` agar evaluasi adil dan berbasis kompetensi.

🛡️ 1. Proteksi Kontak & Data Sensitif (UU PDP)

Sistem mengunci alamat rumah, NIK, email, dan nomor HP pelamar. Jika lowongan membutuhkan kualifikasi keagamaan atau gender khusus (BFOQ), sistem mencocokkannya secara objektif tanpa mengekspos kontak pribadi pelamar.

🎭 2. Token Replacement & Whitelist Role

Nama pelamar disamarkan menjadi `[NAMA]`. Sistem dilengkapi daftar *whitelist* kata profesi (seperti "developer", "engineer", "lead", "analyst") agar kata jabatan tidak ikut tersensor saat menyamarkan nama.

💡 Mengapa Pemisahan Identitas Sangat Penting?

Dengan arsitektur ini, HR Recruiter dan mesin AI mengevaluasi kandidat secara *blind* (buta identitas). Nama asli dan nomor kontak pelamar baru dibuka secara sah (*Reveal Identity*) setelah kandidat dinyatakan lolos ke babak wawancara kerja.

5 Tahap 5: Vector Embedding & Hybrid Semantic Retrieval

Banyak sistem penilaian CV gagal karena hanya mengandalkan pencocokan teks mentah atau sekadar *cosine similarity* sederhana. Sistem kita menggunakan arsitektur pencarian semantik hibrida tingkat tinggi di `src/domain/retrieval.py`.

⚡ Mengapa Bukan Hanya Cosine Similarity Biasa? (Hybrid Retrieval Architecture)

JALUR A: Dense Vector Search (pgvector HNSW)

Teks pengalaman CV diubah menjadi vektor **640 dimensi** menggunakan model **Harrier-270m** (dinormalisasi). Menggunakan indeks HNSW pada PostgreSQL dengan operator jarak kosinus:

`1 - (embedding ⟺ req_vector) AS sim`

Kelebihan: Menangkap kesamaan konsep dan konteks makna meskipun beda kosakata.

JALUR B: Sparse Lexical Search (PostgreSQL FTS)

Pencarian kata kunci presisi menggunakan mesin **Full-Text Search (FTS)** dengan ranking BM25/ts_rank yang diperkaya oleh **Taksonomi Keahlian**:

`ts_rank(fts, plainto_tsquery('simple', query))`

Kelebihan: Menjamin istilah teknis mutlak (seperti "PostgreSQL", "Docker") tertangkap 100%.

JALUR C: RECIPROCAL RANK FUSION (Formula RRF k=60) `Algoritma Fusi`

Sistem menggabungkan peringkat hasil Jalur A dan Jalur B dengan formula matematis RRF:

`Skor RRF = 1 / (60 + Peringkat_Vektor) + 1 / (60 + Peringkat_Keyword)`

Potongan teks yang unggul secara makna semantik **DAN** memuat kata kunci teknis riil akan otomatis naik ke peringkat teratas, menghasilkan bukti otentik (*evidence provenance quote*) tanpa halusinasi.

METODE PENCARIAN	KEKUATAN UTAMA	KELEMAHAN JIKA BERDIRI SENDIRI
Cosine Similarity Murni	Bisa memahami sinonim dan bahasa alami yang bervariasi.	Rentan *false positive* (misal: menganggap MySQL dan PostgreSQL sama, padahal lowongan butuh spesifik PostgreSQL).
Keyword Search Murni (FTS)	100% presisi untuk istilah spesifik dan akronim teknis.	Gagal jika pelamar menuliskan konsep pekerjaan tanpa menyebutkan keyword persis lowongan.
Hybrid RRF (Sistem Kita)	**Kombinasi Terbaik:** Memahami konteks kalimat sekaligus mengunci presisi keyword teknis.	Membutuhkan infrastruktur database modern (PostgreSQL + pgvector). *Sudah aktif 100% di VPS!*

6 Tahap 6: Multi-Criteria Scoring, Banding & Leaderboard

Tahap akhir menghitung skor mutlak pelamar (skala 0.0 – 100.0) secara **deterministik dan dapat diaudit** melalui modul `src/domain/scorer.py`.

STATUS BUKTI	NILAI ANGKA	PENJELASAN LOGIKA PEMENUHAN KRITERIA
`STRONG`	**1.0 (100%)**	Bukti pengalaman riil terverifikasi memenuhi kriteria lowongan secara eksplisit dan mendalam.
`PARTIAL`	**0.5 (50%)**	Kandidat memenuhi kriteria secara semantik (misal pernah menggunakan framework sejenis) atau durasi belum penuh.
`NOT_DEMONSTRATED`	**0.0 (0%)**	Tidak ada bukti relevan yang ditemukan di dalam resume pelamar.

📊 **Rumus Perhitungan Skor Dua Lapis (Two-Layer Normalization):**

1. *Skor Kategori* = (Total Poin Kriteria Didapat ÷ Total Bobot Kriteria di Kategori Tersebut) × 100
2. *Skor Akhir* = Σ (Skor Kategori × Bobot Persentase Kategori)

Contoh: Skor Pengalaman (80) × 40% + Skor Skill (90) × 30% + Pendidikan (100) × 15% + Prestasi (70) × 15% = ***84.5 (Band A)***

.

BAND	RENTANG NILAI	REKOMENDASI HR	ATURAN PENGUNCIAN BATAS ATAS (HARD CAPPING)
BAND A	Skor **70.0 – 100.0**	`SHORTLIST`	Seluruh syarat Wajib (MUST_HAVE) terpenuhi dengan status `STRONG`.
BAND B	Skor **50.0 – 69.9** (Maks 74.0)	`REVIEW`	Jika ada **1 syarat Wajib** yang tidak terpenuhi, skor langsung di-cap maksimal ke 74.0.
BAND C	Skor **< 50.0** (Maks 49.0)	`LOW_PRIORITY`	Jika ada **≥ 2 syarat Wajib** yang tidak terpenuhi, skor langsung di-cap maksimal ke 49.0.
BAND R	Skor **0.0**	`REJECTED_NOT_A_CV`	Dokumen bukan-CV (dicegat di Tahap 2) atau berkas rusak / kosong.

7 Tahap 7: Dashboard HR, Audit Trail & Human Decision

Keluaran akhir disajikan melalui antarmuka web interaktif di `https://screening.rifqisetiawan.my.id` yang menjunjung tinggi kendali manusia (*Human-in-the-Loop*):

🏆 1. Leaderboard Ranking & Filter Band

Papan peringkat real-time menampilkan urutan kandidat berdasarkan skor final. Recruiter dapat menyaring berdasarkan Band A, B, C, atau tab khusus penolakan bukan-CV.

🔍 2. Candidate Detail Drawer & Evidence

Saat kandidat diklik, muncul panel audit yang membedah nilai per kriteria, lengkap dengan **kutipan kalimat asli (quote)** dari CV sebagai bukti kenapa kriteria tersebut dinilai terpenuhi.

👁️ 3. Fitur Buka Identitas (Reveal Identity)

Identitas asli pelamar (nama, email, WhatsApp) tetap tersembunyi selama proses evaluasi. Recruiter baru menekan tombol *"Buka Identitas"* ketika kandidat sudah diputuskan lolos ke tahap interview.

⚖️ 4. Gate Kelayakan Administratif Terpisah

Sesuai SE Menaker 2025, syarat administratif seperti domisili atau usia minimum tidak digabung ke dalam skor kompetensi, melainkan diuji pada pintu kelayakan tersendiri dengan status `ELIGIBLE / NOT_ELIGIBLE`.

📌 Ringkasan Nilai Keunggulan & Kesiapan Produksi Sistem:

✔
100% Akurasi Ekstraksi:
Teruji pada 54 CV nyata dengan nol anomali nama dan zero truncated history.
✔
Bebas Bias & Patuh UU PDP:
Anonimisasi identitas melindungi rekruter dari diskriminasi gender, suku, dan agama.
✔
Transparan & Terbukti:
Setiap skor memiliki kutipan bukti asli dari resume kandidat tanpa halusinasi.
✔
Kontrol Penuh HR:
Pembobotan 4 kategori dan per kriteria dapat diatur secara live di antarmuka Web UI.
✔
Efisien & Skalabel:
Memangkas waktu penyaringan ratusan CV dari hitungan hari menjadi hitungan menit.

© 2026 Platform AI CV Screening & Ranking • Dikembangkan oleh Muhammad Rifqi Setiawan • Dokumen Teknis Resmi